主题驱动的多源视频自动编排系统设计与实现文献综述

Last edited time	@March 17, 2026 10:42 AM
Status	Not started

1. 引言

近年来，短视频平台和移动拍摄设备的普及使视频素材的获取变得越来越容易，但后续整理和剪辑仍然主要依赖人工完成。尤其是在用户只给出一个抽象主题的情况下，如何从多源视频中找出相关片段，并进一步组织成内容连贯的视频，往往需要耗费较多时间和精力。因此，围绕“主题驱动的视频自动编排”开展研究，具有较强的现实意义。本课题希望在这一背景下，设计并实现一个**主题驱动的多源视频自动编排系统**。

要实现这样的系统，单靠单一算法模块是不够的。它至少涉及文本-视频检索、视频摘要、镜头边界检测、自动视频剪辑等几个方向。结合当前项目的实际推进情况，还需要进一步考虑 `AI Agent` 在任务拆解、工具调度和上下文组织中的作用。这里讨论 `AI Agent`，并不是要把课题转成纯智能体研究，而是因为当系统要处理“按主题检索素材、对候选片段继续判断、再完成编排”这类多步骤任务时，固定流程往往不够灵活。基于这一点，下面将围绕上述几个方向梳理相关研究。

2. 视频检索与摘要技术研究现状

2.1 文本-视频跨模态检索 (Text-to-Video Retrieval)

主题驱动的视频编排首先要解决的是素材检索问题，也就是如何把用户输入的主题与视频内容对应起来。早期方法较多依赖人工标签、关键词或规则匹配，这类方法在数据规模较小时还能使用，但在面对大规模、缺少标注的原始视频时效果有限。近年来，随着 `CLIP` 一类视觉语言预训练模型的发展，文本与图像、视频之间的跨模态对齐能力得到了明显提升。`CLIP4Clip` [1] 将这一思路扩展到视频检索任务中，说明预训练表示能够较好地支持视频片段与文本之间的语义匹配。在此基础上，后续研究又继续关注检索效率和特征表达方式，例如 `TeachCLIP` [2] 强调全局特征在视频检索中的作用。对于本课题而言，这些研究提供了较直接的方法参考，即将用户主题转化为可计算的语义查询，再从多源视频中筛出一批候选片段，供后续筛选和编排使用。

2.2 视频摘要与内容提炼 (Video Summarization)

在得到一批候选素材之后，系统还需要进一步判断哪些内容值得保留。视频摘要方向研究的正是如何从较长的视频中提取更有代表性的片段。`Tiwari` 等人的综述 [3] 对这一方向进行了较为系统的整理，其中较有代表性的一类思路，是通过模型为不同片段分配重要性分数，再据此完成筛选。整体来看，视频摘要研究已经不再局限于画面变化检测或关键帧提取，而是越来越强调语义信息、时序关系以及用户需求本身。对于本课题而言，这一点具有直接意义，因为“是否符合主题”本身就是一种带有语义约束的筛选过程，而不是简单地保留画面最活跃或变化最大的部分。

3. 视频切分与自动剪辑逻辑

3.1 镜头边界检测 (Shot Boundary Detection)

如果不先把长视频切分成较小、相对稳定的片段，后续检索和编排都很难开展。因此，镜头边界检测是整个流程中的基础步骤。它的目标是识别镜头之间的切换位置，把连续视频切成可以进一步处理的单位。`Geng` 等人 [4] 的研究表明，多任务学习能够提升镜头边界检测在复杂转场场景下的稳定性；`Kar` 等人 [5] 的综述则较系统地总结了这一方向的主要方法和难点。对本课题而言，镜头切分并不是一个附属环节，而是后续按主题检索、筛选和重组素材的前提。

3.2 自动化视频剪辑 (Automatic Video Editing)

自动化视频剪辑关注的并不只是片段拼接本身，而是如何在保留主题的前提下，使最终结果在内容和节奏上都尽量连贯。已有研究指出，智能剪辑的主要难点在于叙事一致性、节奏控制和主题相关性之间的平衡 [6]。这一点对本课题的启发在于，系统不能停留在单步筛选上，而需要继续对候选片段做排序、取舍和组合。也就是说，真正困难的部分不仅在于找到相关素材，还在于决定这些素材应当以什么方式被使用。

4. AI Agent 设计与智能化工作流

在当前项目中，引入 `AI Agent` 的原因比较明确：主题驱动的视频编排不是单一步骤就能完成的任务，而是一个需要多轮判断和多种工具协作的过程。根据 `Wang` 等人 [7] 的总结，基于 `LLM` 的自主智能体通常采用“感知-规划-行动”的基本框架来处理复杂任务。对应到本课题中，可以把它理解为一种 `Planner-Executor` 模式，即系统先根据主题拆解任务，再调用不同处理能力完成检索、判断和编排。这样做的意义在于，原本分散的步骤可以被组织成一个相对清晰的工作流，而不是依赖零散规则强行拼接。

`Masterman` 等人 [8] 对单智能体和多智能体在推理、规划及工具调用上的差异进行了比较，这对本项目中的 `Agent Runtime` 设计具有直接参考价值。因为当系统开始调用多个工具之后，核心问题就不再只是“模型能否生成回答”，而是“每一步应该做什么、结果如何回收、失败之后怎样继续”。同时，`Chen` 等人 [9] 对多智能体协作和基础设施问题的讨论，也提醒我们要重视 `Context Assembly` 这类对最终效果影响很大的环节。对

于多源视频素材而言，如果把无关信息大量送入模型，上下文很容易失控，因此如何有选择地组织输入，本身也是系统设计的重要组成部分。

5. 系统架构与工程管线 (System Engineering)

从工程实现角度看，本课题最终落地的不会只是几个独立算法，而是一个需要持续扩展、调试和维护的系统。因此，当前项目采用了 `Client-Core-Server` 的三层结构，尽量将界面交互、本地能力和服务端能力分开。`Xu` 等人 [10] 在工业级 `Agent` 系统设计方面强调了模块边界、评估和可观测性的重要性，这与本项目当前的推进方向较为一致。另一方面，`Agent-OS` [11] 这类工作虽然仍然偏概念化，但其中关于资源调度、运行时隔离和安全边界的讨论，仍可作为服务端设计时的参考。

就目前进展来看，系统的总体方向已经比较明确，`Client`、`Core`、`Server` 的模块边界也基本划定。围绕编排智能体的运行时骨架、工具契约和部分实现，当前已经形成了一定的文档和代码基础。接下来更重要的工作，不是继续扩展概念，而是把已有设计逐步接起来，包括上下文组装、核心能力集成和服务端稳定性验证。

6. 总结

总体来看，主题驱动的多源视频自动编排并不是一个单点问题，而是由视频检索、摘要、切分、自动剪辑和系统工程共同构成的综合任务。对本课题而言，`AI Agent` 的作用并不在于替代所有算法模块，而在于把这些原本分散的能力组织成一个可以逐步决策的流程。上述文献为本课题提供了较清楚的技术背景，也表明后续工作应继续围绕“如何把已有能力真正连接成一个可用系统”这一核心问题展开。

参考文献

[1] Luo, H., et al. (2021). CLIP4Clip: An Empirical Study of CLIP for End to End Video Clip Retrieval. *arXiv preprint*.

[2] Tian, K., et al. (2024). Holistic Features are almost Sufficient for Text-to-Video Retrieval. *CVPR*.

[3] Tiwari, V., et al. (2021). A survey of recent work on video summarization: approaches and techniques. *Multimedia Tools and Applications*.

[4] Geng, S., et al. (2021). Better Learning Shot Boundary Detection via Multi-task. *ACM MM*.

[5] Kar, T., et al. (2024). Video shot-boundary detection: issues, challenges and solutions. *Artificial Intelligence Review*.

[6] AI Video Editing: a Survey. (2022). *Preprint*.

[7] Wang, L., et al. (2024). A Survey on Large Language Model based Autonomous Agents. *Frontiers of Computer Science*.

[8] Masterman, T., et al. (2024). The Landscape of Emerging AI Agent Architectures for Reasoning, Planning, and Tool Calling: A Survey. *arXiv*.
[9] Chen, S., et al. (2024). A Survey on LLM-based Multi-agent Systems: Workflow, Infrastructure, and Challenges. *arXiv*.
[10] Xu, B., et al. (2026). AI Agent Systems: Architectures, Applications, and Evaluation. *arXiv*.
[11] Agent Operating Systems (Agent-OS): A Blueprint Architecture. (2025). *Preprint*.