外文文献翻译

Last edited time	@March 17, 2026 11:03 AM
Status	Not started

新兴 AI 智能体推理、规划与工具调用架构综述

摘要 (Abstract)

本综述深入探讨了人工智能智能体（AI Agent）实现领域的最新进展，尤其关注它们在达成复杂目标时所展现出的增强型推理（Reasoning）、规划（Planning）及工具执行（Tool Execution）能力。本研究的核心目标有三：首先，阐明现有 AI Agent 实现的当前能力与局限性；其次，分享我们通过观察这些系统实际运行所获得的深刻见解；最后，为未来 AI Agent 设计的发展方向提出关键考量。为实现这些目标，我们对单智能体（Single-Agent）和多智能体（Multi-Agent）架构进行了全面概述，识别了设计选择中的核心模式与分歧，并评估了这些选择对实现既定目标的整体影响。本研究的贡献在于，它勾勒出在选择智能体架构时应考虑的关键主题，包括领导力对智能体系统的作用、智能体间的通信风格，以及支撑稳健 AI Agent 系统所需的规划、执行和反射（Reflection）等关键阶段。

1. 引言 (Introduction)

自 ChatGPT 问世以来，首批生成式人工智能（Generative AI）应用大多以检索增强生成（Retrieval Augmented Generation, RAG）模式为基础，表现为基于文档语料库的聊天变体。尽管目前在提升 RAG 系统的鲁棒性方面仍有大量工作在进行，但各研究团队已开始着手构建下一代 AI 应用的形态，其核心主题均指向“智能体（Agent）”。

从对 GPT-4 等基础模型的研究探索开始，并通过 AutoGPT 和 BabyAGI 等开源项目而广受欢迎，研究界一直在尝试构建基于自主智能体的系统 [19, 1]。

与大语言模型（Large Language Model, LLM）的零样本提示（Zero-shot Prompting）不同——即用户在开放式文本字段中输入内容并直接获得结果，无需额外输入——智能体允许更复杂的交互与编排。具体而言，智能体系统具备规划（Planning）、循环（Loops）、反射（Reflection）及其他控制结构的概念，这些结构能够充分利用模型固有的推理能力，以端到端（End-to-End）的方式完成任务。结

合使用工具（Tools）、插件（Plugins）和函数调用（Function Calling）的能力，智能体被赋予了执行更通用任务的强大潜力。

在学术界，目前关于单智能体系统或多智能体系统哪种更适合解决复杂任务存在争议。当问题定义明确且无需其他智能体角色或用户反馈时，单智能体架构表现卓越；而当任务需要协作和多条独立的执行路径时，多智能体架构则更具优势。

1.1 分类 (Taxonomy)

智能体（Agents）。AI 智能体是基于语言模型驱动的实体，能够通过多次迭代进行规划并采取行动以实现目标。AI 智能体架构可由单个智能体或多个智能体协同工作来解决问题。

通常，每个智能体被赋予一个角色（Persona），并可访问各种工具，以独立或作为团队成员的方式完成其工作。一些智能体还包含记忆（Memory）组件，它们可以在消息和提示之外保存和加载信息。本文遵循“由大脑（Brain）、感知（Perception）和行动（Action）组成”的智能体定义 [31]。这些组件满足了智能体理解、推理并作用于其周围环境的最低要求。

智能体角色（Agent Persona）。智能体角色描述了智能体应扮演的角色或个性，包括针对该智能体的任何其他指令。角色还包含智能体可访问的工具描述。它们使智能体了解自己的职责、工具的用途以及如何有效利用它们。研究人员发现，“塑造的个性可验证地影响大语言模型（LLM）在常见下游（即后续）任务中的行为，例如撰写社交媒体帖子” [21]。使用多个智能体角色解决问题的方案也显示出比思维链（Chain-of-Thought, CoT）提示——即要求模型逐步分解其计划——显著的改进 [28, 29]。

工具（Tools）。在 AI 智能体的语境中，工具代表模型可以调用的任何函数。它们允许智能体通过从外部数据源拉取或向其推送信息来进行交互。一个智能体角色及其相关工具的例子是专业的合同撰写人。该撰写人被赋予一个角色，解释其职责和必须完成的任务类型。它还被赋予了与向文档添加注释、阅读现有文档或发送包含最终草稿的电子邮件相关的工具。

单智能体架构（Single Agent Architectures）。这些架构由一个语言模型驱动，并独立执行所有的推理、规划和工具执行。智能体被赋予一个系统提示（System Prompt）和完成任务所需的任何工具。在单智能体模式中，没有来自其他 AI 智能体的反馈机制；然而，可能存在人类提供反馈以指导智能体的选项。

多智能体架构（Multi-Agent Architectures）。这些架构涉及两个或更多智能体，其中每个智能体可以使用相同的语言模型或一组不同的语言模型。这些智能体可以访问相同的工具或不同的工具。每个智能体通常都有自己的角色。

多智能体架构可以在任何复杂程度上具有多种组织形式。在本文中，我们将其分为两个主要类别：垂直（Vertical）和水平（Horizontal）。重要的是要记住，这些类别代表了一个光谱的两端，大多数现有架构都介于这两个极端之间。

垂直架构（Vertical Architectures）。在这种结构中，一个智能体充当领导者，其他智能体直接向其汇报。根据架构的不同，汇报智能体可能只与领导智能体通信。或者，可以定义一个领导者，所有智能体之间进行共享对话。垂直架构的定义特征包括拥有一个领导智能体以及协作智能体之间明确的分工。

水平架构（Horizontal Architectures）。在这种结构中，所有智能体都被视为平等的，并参与关于任务的集体讨论。智能体之间的通信发生在一个共享线程中，每个智能体都可以看到其他所有智能体的消息。智能体还可以自愿完成某些任务或调用工具，这意味着它们不需要由领导智能体分配。水平架构通常用于协作、反馈和小组讨论对任务整体成功至关重要的任务 [2]。

2. 有效智能体的关键考量 (Key Considerations for Effective Agents)

2.1 概述 (Overview)

智能体的设计旨在扩展语言模型的能力，以解决现实世界的挑战。成功的智能体实现需要具备强大的问题解决能力，使其能够在全新任务上表现出色。为了有效解决现实问题，智能体必须具备推理（Reasoning）和规划（Planning）能力，并能调用与外部环境交互的工具（Tools）。本节将探讨为何推理、规划和工具调用对智能体的成功至关重要。

2.2 推理与规划的重要性 (The Importance of Reasoning and Planning)

推理是人类认知的基础构成要素，它使人们能够做出决策、解决问题并理解周围世界。AI 智能体若要有效与复杂环境互动、自主决策并协助人类完成广泛任务，就必须具备强大的推理能力。这种“行动”与“推理”之间紧密的协同作用，使得新任务能够被快速学习，并能在前所未见的环境或信息不确定性下，实现稳健的决策或推理 [32]。此外，智能体还需要推理能力，以便根据新的反馈或学习到的信息调整其规划。

如果缺乏推理技能的智能体被指派执行直接任务，它们可能会误解查询、基于字面理解生成响应，或者未能考虑多步骤的影响。

规划（Planning）需要强大的推理能力，通常可归为五种主要方法之一：任务分解（Task Decomposition）、多规划选择（Multi-Plan Selection）、外部模块辅助规划（External Module-Aided Planning）、反射与精炼（Reflection and Refinement）以及记忆增强规划（Memory-Augmented Planning）[12]。这些方法允许模型将任务分解为子任务、从多个生成的选项中选择一个规划、利用预先存在的外部规划、根据新信息修订先前的规划，或利用外部信息改进规划。

大多数智能体模式都包含一个专门的规划步骤，该步骤在执行任何行动之前，会调用上述一种或多种技术来创建规划。例如，图式规划（Plan Like a Graph, PLaG）是一种将规划表示为有向图的方法，其中多个步骤可以并行执行 [15, 33]。对于包含许多独立子任务且受益于异步执行的任务，这可以显著提高性能。

2.3 有效工具调用的重要性 (The Importance of Effective Tool Calling)

相较于直接提示基础语言模型，智能体抽象的一个关键优势在于其能够通过调用多个工具来解决复杂问题。这些工具使智能体能够与外部数据源交互、从现有应用程序编程接口（API）发送或检索信息等。需要大量工具调用的问题，往往与需要复杂推理的问题密切相关。

单智能体（Single-Agent）和多智能体（Multi-Agent）架构都可以通过运用推理和工具调用步骤来解决具有挑战性的任务。许多方法利用推理、记忆（Memory）和反射（Reflection）的多次迭代，以有效且准确地完成问题 [16, 23, 32]。它们通常通过将一个大问题分解为更小的子问题，然后按顺序使用适当的工具解决每个子问题来实现这一点。

其他专注于推进智能体模式的研究强调，尽管将大问题分解为更小的子问题可以有效解决复杂任务，但单智能体模式往往难以完成所需的漫长序列 [22, 6]。

多智能体模式可以解决并行任务和鲁棒性（Robustness）问题，因为单个智能体可以处理独立的子问题。许多多智能体模式首先将一个复杂问题分解为几个较小的任务。然后，每个智能体使用自己独立的工具集独立解决每个任务。

3. 单智能体架构 (Single Agent Architectures)

3.1 概述 (Overview)

单智能体架构由一个语言模型驱动，并独立执行所有的推理、规划和工具调用。智能体被赋予一个系统提示（System Prompt）和完成任务所需的任何工具。在单智能体模式中，没有来自其他 AI 智能体的反馈机制；然而，可能存在人类提供反馈以指导智能体的选项。

3.2 关键主题 (Key Themes)

单智能体架构在处理需要深度逻辑推理和特定工具调用的任务时表现出色。有效的单智能体实现通常遵循一个循环的生命周期，包括规划（Planning）、执行（Execution）和反射（Reflection）。

规划 (Planning)

规划阶段是智能体将复杂目标拆解为可管理子任务的过程。主流的规划模式包括思维链（Chain-of-Thought, CoT）和推理与行动（Reasoning and Acting, ReAct）。在 CoT 模式下，智能体通过展示其推理过程来提高复杂问题的解决能力；而 ReAct 模式则更进一步，将推理与外部工具调用紧密结合，允许智能体在每一步行动后根据环境反馈调整其后续规划。

执行 (Execution)

执行阶段涉及具体的工具调用（Tool Calling）。智能体根据规划生成的指令，调用 API、数据库或多媒体处理脚本。在视频编排场景中，这可能包括调用检索模型、剪辑脚本或元数据提取工具。

反射 (Reflection)

反射（Reflection/评估）阶段是提升智能体鲁棒性的关键。智能体通过自我评估或外部反馈来检查执行结果是否符合预期。如果发现偏差，智能体将进入下一个规划循环进行纠错。这种闭环机制（Closed-loop）显著降低了智能体在复杂长链任务中的幻觉（Hallucination）风险。

4. 多智能体架构 (Multi Agent Architectures)

4.1 概述 (Overview)

本节将审视一些关键的多智能体架构研究与示例框架，例如“具身大语言模型智能体学习在有组织团队中协作”（Embodied LLM Agents Learn to Cooperate in Organized Teams）、DyLAN、AgentVerse 和 MetaGPT。我们将重点阐述这些实现如何通过智能体间的通信和协作式规划执行来促进目标达成。此处并非旨在穷尽所有智能体框架，我们的目标是广泛涵盖与多智能体模式相关的关键主题和实例。

4.2 关键主题 (Key Themes)

多智能体架构为基于技能的智能分工以及来自不同智能体角色（Agent Personas）的有效反馈创造了机会。许多多智能体架构在规划、执行和评估的各个阶段，会动态地创建和重组智能体团队 [2, 9, 18]。这种动态重组带来了卓越的成果，因为针对特定任务会启用专门的智能体，并在任务完成后将其移除。通过使智能体的角色和技能与手头的任务相匹配，智能体团队能够实现更高的准确性，并缩短达成目标所需的时间。高效多智能体架构的关键特征包括：智能体团队中明确的领导力（Leadership）、动态的团队构建（Dynamic Team Construction），以及团队成员之间有效的信息共享，以确保重要信息不会在冗余的“闲聊”（superfluous chatter）中丢失。

4.3 示例 (Examples)

具身大语言模型智能体学习在有组织团队中协作。Guo 等人 [9] 的研究展示了领导智能体对智能体团队整体效能的影响。该架构通过领导智能体包含一个垂直组件，同时通过智能体之间除领导者外也能相互交流的能力，包含一个水平组件。他们的研究结果表明，拥有有组织领导者的智能体团队完成任务的速度比没有领导者的团队快近 10%。

此外，他们发现，在没有指定领导者的团队中，智能体大部分时间都花在相互下达指令上（约占通信的 50%），剩余时间则用于分享信息或请求指导。相反，在有指定领导者的团队中，领导者 60% 的通信涉及下达指令，促使其他成员更多地专注于信息交换和请求。他们的结果表明，当领导者是人类时，智能体团队效率最高。

超越团队结构，该论文强调了采用“批评-反思”（criticize-reflect）步骤对于生成规划、评估绩效、提供反馈和重组团队的重要性 [9]。他们的结果表明，具有动态团队结构和轮流领导的智能体提供了最佳结果，平均任务完成时间最短，通信成本也最低。最终，领导力和动态团队结构提高了团队整体的推理、规划和有效执行任务的能力。

DyLAN。动态大语言模型智能体网络（Dynamic LLM-Agent Network, DyLAN）框架创建了一种动态智能体结构，专注于推理和代码生成等复杂任务 [18]。DyLAN 有一个特定步骤，用于确定每个智能体在上一轮工作中贡献了多少，并且只将贡献最大的智能体移至下一轮执行。这种方法本质上是水平的，因为智能体可以相互共享信息，并且没有明确的领导者。DyLAN 在衡量算术和通用推理能力的各种基准测试中表现出改进的性能。这突显了动态团队的影响，并表明通过持续重新评估和排名智能体贡献，我们可以创建更适合完成给定任务的智能体团队。

AgentVerse。AgentVerse 等多智能体架构展示了明确的群体规划阶段如何提高 AI 智能体的推理和问题解决能力 [2]。AgentVerse 包含任务执行的四个主要阶段：招募（recruitment）、协作决策（collaborative decision making）、独立行动执行（independent action execution）和评估（evaluation）。这个过程可以重复，直到实现总体目标。通过严格定义每个阶段，AgentVerse 有助于引导智能体集合更有效地进行推理、讨论和执行。

例如，招募步骤允许根据目标进展移除或添加智能体。这有助于确保在问题解决的任何给定阶段都有合适的智能体参与。研究人员发现，水平团队通常最适合咨询等协作任务，而垂直团队则更适合需要更明确的工具调用职责隔离的任务。

4.4 通信与协作示例 (Examples of Communication and Collaboration)

许多多智能体架构允许智能体在协作处理共同问题时相互交流。这种对话能力可能导致智能体之间产生冗余的、无助于进一步实现团队目标的“闲聊”（chatter）。MetaGPT 通过要求智能体生成文档和图表等结构化输出（Structured Outputs），而非共享非结构化聊天消息，解决了智能体之间低效闲聊的问题 [11]。

此外，MetaGPT 实现了信息共享的“发布-订阅”（Publish-Subscribe）机制。这使得所有智能体可以在一个地方共享信息，但只读取与其个人目标和任务相关的信息。这简化了整体目标的执行，并减少了智能体之间的通信噪声。与单智能体架构在 HumanEval 和 MBPP 基准测试上的表现相比，MetaGPT 的多智能体架构展示了显著更优的结果。

5. 讨论与观察 (Discussion and Observations)

5.1 概述 (Overview)

本节将探讨前述智能体模式中设计选择的关键主题及其影响。这些模式是 AI 智能体架构研究与实现不断增长的典范。单智能体和多智能体架构都致力于通过赋予语言模型代表或协同人类用户执行目标的能力，来增强其功能。大多数观察到的智能体实现都普遍遵循“规划、行动和评估”的迭代过程来解决问题。

我们发现，单智能体和多智能体架构在执行复杂目标方面都展现出令人信服的性能。同时，我们还观察到，在各种架构中，清晰的反馈机制、任务分解、迭代精炼和角色定义都能提升智能体的表现。

5.2 关键发现 (Key Findings)

单智能体与多智能体架构选择的典型条件。基于上述智能体模式，我们发现单智能体模式通常最适合工具列表定义明确且流程清晰的任务。单智能体通常也更容易实现，因为只需定义一个智能体和一套工具。此外，单智能体架构不会面临来自其他智能体反馈不佳或来自其他团队成员的干扰性、不相关“闲聊”等限制。然而，如果其推理和精炼能力不够稳健，它们可能会陷入无限的执行循环，无法朝着目标取得进展，或返回不符合用户预期的结果。

多智能体架构通常非常适合那些需要多角色反馈才能有效完成任务的场景。例如，文档生成可能受益于多智能体架构，其中一个智能体可以就文档的某个书写部分向另一个智能体提供清晰的反馈。当需要跨不同任务或工作流进行并行化时，多智能体系统也很有用。至关重要的是，Wang 等人发现，在没有提供示例的情况下，多智能体模式在某些场景下表现优于单智能体 [26]。从本质上讲，多智能体系统更为复杂，通常受益于稳健的对话管理和明确的领导力。

尽管单智能体和多智能体模式在范围上具有不同的能力，但研究发现，“当提供给智能体的提示足够稳健时，多智能体讨论不一定会增强推理能力” [26]。这表明，智能体架构的实施者应根据其用例的更广泛背景，而非所需的推理能力，来决定采用单智能体还是多智能体。

智能体与异步任务执行。虽然单个智能体可以同时发起多个异步调用，但其操作模型并未固有地支持跨不同执行线程的职责划分。这意味着，尽管任务是异步处理的，但

它们并非真正意义上的并行，即不具备由独立的决策实体自主管理的能力。相反，单个智能体必须顺序地规划和执行任务，等待一批异步操作完成后才能评估并进入下一步。反之，在多智能体架构中，每个智能体可以独立运作，从而实现更动态的劳动分工。这种结构不仅促进了跨不同领域或目标的同步任务执行，还允许单个智能体在不受其他智能体处理任务状态阻碍的情况下推进其下一步骤，体现了更灵活和并行的任务管理方法。

反馈与人工监督对智能体系统的影响。在解决复杂问题时，第一次尝试就提供正确、稳健的解决方案是极其罕见的。相反，人们可能会先提出一个潜在解决方案，然后对其进行批判并加以完善。也可以咨询他人，从不同角度获得反馈。这种迭代反馈和精炼的理念对于帮助智能体解决复杂问题至关重要。

部分原因在于语言模型倾向于在响应早期就确定答案，这可能导致其偏离目标状态的“滚雪球效应” [34]。通过实施反馈机制，智能体更有可能纠正其方向并达成目标。

此外，引入人工监督可以改善即时结果，使智能体的响应更符合人类预期，从而减轻智能体陷入低效或无效任务解决方法的可能性。截至目前，在智能体架构中纳入人工验证和反馈能够产生更可靠、更值得信赖的结果 [4, 9]。

语言模型还表现出“谄媚行为”（sycophantic behavior），即它们“倾向于迎合用户的立场，即使这意味着放弃呈现公正或平衡的观点” [20]。具体而言，AgentVerse 论文描述了智能体如何容易受到其他智能体反馈的影响，即使该反馈并不合理。这可能导致智能体团队生成错误的规划，使其偏离目标 [2]。稳健的提示（Robust Prompting）有助于缓解这种情况，但开发智能体应用程序的人员在实施用户或智能体反馈系统时应注意这些风险。

群体对话与信息共享的挑战。多智能体架构的一个挑战在于其智能地在智能体之间共享消息的能力。多智能体模式更容易陷入客套和相互询问“你好吗”之类的问题，而单智能体模式往往更专注于手头的任务，因为没有团队动态需要管理。多智能体系统中多余的对话会损害智能体有效推理和执行正确工具的能力，最终分散智能体对任务的注意力并降低团队效率。在水平架构中尤其如此，因为智能体通常共享一个群聊，并且可以查看对话中所有其他智能体的消息。消息订阅或过滤通过确保智能体只接收与其任务相关的信息来提高多智能体性能。

在垂直架构中，任务往往根据智能体技能明确划分，这有助于减少团队中的干扰。然而，当领导智能体未能向其支持智能体发送关键信息，并且没有意识到其他智能体不了解必要信息时，就会出现挑战。这种失败可能导致团队混乱或结果出现幻觉。解决此问题的一种方法是在系统提示中明确包含访问权限信息，以便智能体能够进行上下文适当的交互。

角色定义与动态团队的影响。清晰的角色定义对于单智能体和多智能体架构都至关重要。在单智能体架构中，角色定义确保智能体专注于提供的任务，执行适当的工具，并最大限度地减少对其他能力的幻觉。同样，多智能体架构中的角色定义确保每个智

能体都知道自己在整个团队中负责什么，并且不会承担超出其描述能力或范围的任务。除了个体角色定义之外，建立明确的团队领导者还可以通过简化任务分配来提高多智能体团队的整体绩效。此外，为每个智能体定义清晰的系统提示可以最大限度地减少多余的闲聊，通过提示智能体不要进行低效的沟通。

根据需要将智能体引入和移出系统的动态团队也被证明是有效的。这确保了参与规划或执行任务的所有智能体都适合该轮工作。

5.3 总结 (Summary)

单智能体和多智能体模式在涉及推理和工具执行的各种复杂任务中都表现出强大的性能。当被赋予明确的角色和工具集、人工反馈的机会以及迭代地朝着目标工作的能力时，单智能体模式表现良好。在构建需要协作完成复杂目标的智能体团队时，部署具有以下至少一个关键元素的智能体是有益的：明确的领导者、明确的规划阶段以及在学习到新信息时完善规划的机会、智能消息过滤以及具有与当前子任务相关的特定技能的动态团队。如果智能体架构采用这些方法中的至少一种，则与单智能体架构或不具备这些策略的多智能体架构相比，其性能可能会有所提高。

6. 当前研究的局限性与未来研究的考量 (Limitations of Current Research and Considerations for Future Research)

6.1 概述 (Overview)

本节将审视当前智能体研究的一些局限性，并指出改进 AI 智能体系统的潜在领域。尽管智能体架构在许多方面显著增强了语言模型的能力，但在评估、整体可靠性以及从驱动每个智能体的语言模型继承的问题方面，仍存在一些重大挑战。

6.2 智能体评估的挑战 (Challenges with Agent Evaluation)

虽然大语言模型（LLM）通过一套标准基准进行评估，旨在衡量其通用理解和推理能力，但智能体评估的基准却差异巨大。

许多研究团队在实现智能体的同时引入了自己独特的智能体基准，这使得在同一基准上比较多个智能体实现变得具有挑战性。此外，许多这些新的智能体特定基准包含手工制作的、高度复杂的评估集，其结果是手动评分的 [2]。这可以提供对方法能力的高质量评估，但它也缺乏更大数据集的鲁棒性，并存在在评估中引入偏差的风险，因为开发方法的人员也负责编写和评分结果。由于模型、环境或问题状态的可变性，智能体在多次迭代中生成一致答案也可能存在问题。这种增加的随机性对较小、复杂的评估集构成了更大的问题。

6.3 数据污染与静态基准的影响 (Impact of Data Contamination and Static Benchmarks)

一些研究人员在典型的 LLM 基准上评估他们的智能体实现。新兴研究表明，模型的训练数据存在显著的数据污染，这一观察结果得到了支持：当基准问题被修改时，模型的性能会显著下降 [8, 38, 37]。这使得人们对语言模型和语言模型驱动的智能体的基准分数真实性产生怀疑。

此外，研究人员发现，“随着 LLM 快速发展，现有数据集通常无法匹配模型不断演进的能力，因为现有基准的复杂性水平通常是静态和固定的” [37]。为了解决这个问题，已经开展了创建能够抵抗简单记忆的动态基准的工作 [38, 37]。研究人员还探索了根据用户的特定环境或用例生成完全合成基准的想法 [14, 27]。虽然这些技术有助于解决数据污染问题，但减少人工参与的程度可能会在正确性和解决问题的能力方面带来额外的风险。

6.4 基准范围与可迁移性 (Benchmark Scope and Transferability)

许多语言模型基准旨在通过单次迭代解决，不涉及工具调用，例如 MMLU 或 GSM8K [3, 10]。虽然这些对于衡量基础语言模型的能力很重要，但它们并非智能体能力的良好替代指标，因为它们没有考虑智能体系统通过多步骤推理或访问外部信息的能力。StrategyQA 通过评估模型在多步骤上的推理能力来改进这一点，但答案仅限于“是/否”响应 [7]。随着行业继续转向以智能体为中心的用例，将需要额外的衡量标准来更好地评估智能体在涉及超出其训练数据范围的工具任务上的性能和泛化能力。

一些智能体特定基准，如 AgentBench，在各种不同环境（如网页浏览、命令行界面和视频游戏）中评估基于语言模型的智能体 [17]。这为智能体如何通过推理、规划和调用工具来泛化到新环境提供了更好的指示。AgentBench 和 SmartPlay 等基准引入了客观评估指标，旨在评估实现的成功率、输出与人类响应的相似性以及整体效率 [17, 30]。虽然这些客观指标对于理解实现的整体可靠性和准确性很重要，但考虑更细微或主观的性能衡量标准也同样重要。诸如工具使用效率、可靠性和规划鲁棒性等指标几乎与成功率一样重要，但更难衡量。其中许多指标需要人类专家进行评估，这与“LLM 作为评判者”的评估相比，成本高昂且耗时。

6.5 实际应用性 (Real-world Applicability)

许多现有基准侧重于智能体系统解决逻辑谜题或视频游戏的能力 [17]。虽然评估这些类型任务的性能有助于了解智能体系统的推理能力，但这些基准上的性能是否能转化为实际世界中的性能尚不明确。具体而言，真实世界的数据可能嘈杂，并且涵盖更广泛的主题，而许多常见基准缺乏这些主题。

一个使用真实世界数据的流行基准是 WildBench，它来源于 WildChat 数据集，该数据集包含 570,000 条与 ChatGPT 的真实对话 [35]。因此，它涵盖了广泛的任务和提

示。虽然 WildBench 涵盖了广泛的真实世界任务，但它主要关注对话式智能体，可能无法完全捕捉到需要复杂工具调用和环境交互的智能体系统的性能。

7. 结论与未来方向 (Conclusion and Future Directions)

本综述深入探讨了 AI 智能体架构的最新进展，重点关注其在推理、规划和工具调用方面的能力。我们审视了单智能体和多智能体架构，强调了它们各自的优势和局限性，并讨论了影响其性能的关键设计考量。智能体系统在扩展语言模型能力以解决复杂现实世界问题方面展现出巨大潜力，但其评估、可靠性和实际应用性仍面临挑战。

未来的研究方向应侧重于开发更稳健、更可泛化的评估基准，以更好地衡量智能体在复杂、动态环境中的表现。同时，探索更高效的上下文管理机制、提升智能体在长序列任务中的鲁棒性，以及优化人机协作模式，将是推动 AI 智能体技术走向成熟的关键。通过持续的创新和跨学科合作，AI 智能体有望在更多领域实现自主决策和行动，为人类社会带来深远影响。